

Использование генеративных нейронных сетей для трансфера изображений *радиолокационного* диапазона в *оптический*

Автор

Селин Тимур
Александрович
Студент 401а группы

Научный руководитель

Завьялова Наталья
Александровна
к.ф.-м.н., доцент

Научный консультант

Абрамов Владимир
Сергеевич
Ассистент ЦОП ФАКТ МФТИ

Актуальность и *постановка проблемы*

- ◆ Радиолокаторы с синтезированной апертурой (РСА, SAR) снимают всепогодно и круглосуточно, сквозь облачность.
- ◆ Но радиолокационное изображение (РЛИ) трудно интерпретировать: спекл-шум, уникальные для них геометрические искажения, объекты в радиолокационном диапазоне отличаются по виду от оптических
- ◆ Решение — кросс-модальный перевод РЛИ → оптика генеративной сетью с сохранением структуры сцены
- ◆ Лучшие по качеству диффузионные модели являются вычислительно сложными для практического применения → нужна лёгкая и быстрая архитектура



Пара РЛИ / оптический эталон

Цель и *задачи работы*

Цель — повышение качества и интерпретируемости данных ДЗЗ за счет разработки и исследования метода трансфера РЛИ → ОРТ

- 1 Сформировать набор данных, включающий совмещенные пары РЛИ и оптических изображений
- 2 Разработать архитектуру с учетом особенностей РЛИ и ограниченных вычислительных ресурсов
- 3 Провести эксперименты и сделать сравнительный анализ с существующими решениями



Научная *новизна*

Применимо к текущей задаче

- 1 Предложена архитектура с прямым преобразованием Хаара в начале и обратным в конце
- 2 Предложен высокочастотный дискриминатор — критик, который работает только с резкими деталями
- 3 Два подтвержденных отрицательных результата, мотивирующих выбор


Данные и *метрики*

- ◆ Основной набор данных — **SEN1-2** (пары Sentinel-1 и Sentinel-2)
- ◆ Обучение на 5 сценах: 11 315 пар **256×256**
- ◆ Метрики **PSNR**, **SSIM** (пиксельные) и **FID**, **LPIPS** (перцептивные)



Пары РЛИ / оптический эталон (SEN1-2)

Предлагаемая модель *WaveNeXt*




WaveNeXt: *Адаптер*




Исходное РЛИ



Фильтр Ли




Собель



Разность РЛИ - Ли

WaveNeXt: *Хаар*



- ◆ LL — низкочастотная аппроксимация (уменьшенная копия сцены)
- ◆ LN — вертикальные края, HL — горизонтальные.
- ◆ HH — диагонали и мелкая текстура
- ◆ В первичном блоке применяется двухуровнево, дополнительно обучается только проекция 1×1

Преобразование Хаара

Один уровень: LL (↖), HL (↗), LH (↘), HH (↙)

WaveNeXt: мотивация *HF-D*

Профиль ошибки: цвет восстановлен, дефицит в средних и высоких частотах (размытие).
Медианный сдвиг пар $\approx 1,23$ пикселя.

Компромисс «размытие — галлюцинации» (perception-distortion, Blau & Michaeli, 2018)

Снижать искажение и повышать реализм одновременно нельзя.
Пиксельные потери минимизируют искажение → безопасное размытие.
Перцептивные потери → реализм и резкость ценой галлюцинаций.

Возможные решения

Сопоставить изображения пиксель-в-пиксель
(Доля пар со сдвигом $>1\text{px}$ — 58%; $>2\text{px}$ — 31%; $>5\text{px}$ — 10%)

Использовать инвариантные к сдвигу потери
(Sliced Wasserstein Distance)

Вывод

Разная природа, локально яркости почти не связаны
($NCC \approx 0,02$), нет соответствия для выравнивания



SWD оценивает резкость, но не создает ее. Совпадение
распределения деталей не задаёт их расположение

- ✓ Нужен сигнал, который локализован в пространстве (знает куда ставить деталь), устойчив к сдвигу (судит реализм), сфокусирован у границ, где дефицит деталей и РЛИ-обусловленный против галлюцинаций. Получаем условный дискриминатор на высоких частотах.

Высокочастотный дискриминатор *HF-D*

- ◆ Высокочастотный остаток: $h(x) = x - g_{\sigma} * x$, $\sigma=2$.
- ◆ Работает только при обучении
- ◆ Обучается отличать реальные и сгенерированные изображения

Tiny	$\lambda_{HF-D}=0$	$\lambda_{HF-D}=1$
PSNR $\uparrow$	17.04	17.16
SSIM $\uparrow$	0,352	0,347
FID $\downarrow$	≈ 84	≈ 75
LPIPS $\downarrow$	0,330	0,301




Верх – основной PatchGAN, низ – HF-D на остатке $h(\text{оптика})$

Абляция и вклад компонентов

Конфигурация	PSNR ↑	SSIM ↑	FID ↓	LPIPS ↓
LLW-Former Base (финал)	18,54	0,432	58,5	0,241
Кол-во парам. backbone (Tiny)	17,28	0,369	73,0	0,311
Выравнивание пар	17,06	0,348	84,0	0,314
Перцептивные потери	14,85	0,297	91,5	0,422
Покомпонентная Хаар-потеря	13,02	0,273	87,5	0,438
Обратный Хаар (RGB-голова)	12,91	0,265	73,5	0,436

Визуальный пример вклада HF-D



Функции *потерь*

Потеря	Что сравнивает	Смысл / домен	Вес
Adversarial Main-D	MSE карты логитов	общий реализм + соответствие SAR	1
Adversarial HF-D	MSE карты логитов на ВЧ	реализм высоких частот (резкость)	1
Feature Matching	L1 промежуточных активаций D(fake) и D(real), послойно	стабильность + перенос деталей	10
MS-SSIM	Яркость, контраст, структура по окнам, многомасштабно	структура и контраст	1
LPIPS	L2 признаков fake и real в предобученной AlexNet	перцептивное качество	2
FFL	взвеш. MSE FFT(fake) и FFT(real)	частотный домен	10
Per-band Хаар L1	L1 суб-полос и Haar(real) по полосам (LL·1 LH·1,5 HL·1,5 HH·2)	детали по ориентациям	2
PatchNCE	Похожесть части изобр. на свой эталон, а не на другие	сохранение содержания	0.1

Сравнение с *существующими моделями*

Модель	PSNR ↑	SSIM ↑	FID ↓	LPIPS ↓
LLW-Former Base (финал)	18,54	0,432	58,5	0,241
LLW-Former Tiny	17,28	0,369	73,0	0,311
Pix2Pix	12,79	0,179	113,9	0,483
CycleGAN	11,54	0,172	89,4	0,497
CFRWD-GAN	17,2–18,3	0,29–0,35	116–150	0,31–0,37
E³Diff (диффузия)	18,84	0,421	65,2	0,366

Сравнение с *существующими моделями*


Модель	Параметры	GPU	CPU	VRAM*
LLW-Former Tiny	35,06 млн	7,87 мс	59,5 мс	167 МБ
Базовый ConvNeXt V2	41,85 млн	8,03 мс	60,9 мс	197 МБ
CFRWD (реимпл.)	2,40 млн	19,76 мс	186 мс	229 МБ

* VRAM — только веса и тензоры. CUDA-контекст (≈1387 МБ) фиксирован и одинаков для всех моделей.

- ◆ У CFRWD в ~15 раз меньше параметров, но она в ~2,5 раза медленнее из-за недостаточной оптимизации
- ◆ Блоки ConvNeXt V2 имеют меньшее количество операций, крупные свертки, что лучше распределяется на ГПУ. В то же время много мелких сверткок в CFRWD в недостаточной мере нагружают ГПУ
- ◆ LLW-Former превосходит CFRWD одновременно по скорости, памяти и качеству

Выводы

- 1 Разработана лёгкая архитектура LLW-Former (ConvNeXt V2 + замкнутый Хаар-контур)
- 2 Предложен высокочастотный дискриминатор HF-D
-8,8% LPIPS и -11% FID при стабильном обучении, без затрат на инференсе
- 3 Получены два самостоятельных негативных результата ($NCC \approx 0,02$, SWD оценивает резкость, но не порождает), мотивирующих состязательный механизм.
- 4 По FID (58–73) и LPIPS (0,24–0,31) модель превосходит опубликованные GAN- и диффузионные подходы на SEN1-2, по PSNR/SSIM сопоставима с лучшими — при существенно меньшей стоимости инференса.




Пример результата работы LLW-Former Base


Спасибо за внимание!

Готов ответить на вопросы


Декодер *PixelShuffle*



Каждые r^2 соседних каналов образуют один $r \times r$ под-пиксельный блок в пространстве выхода. Разрешение $\times r$, каналов $\div r^2$.




Выходы блоков. *Генератор*




Выходы блоков. Дискриминатор. *Main-D*

Main-D · coarse (70×70 RF)




Main-D · fine (46×46 RF)



Выходы блоков. Дискриминатор. *HF-D*

HF-D • (70×70 RF)




РЛИ
1×256×256


+




ВЧ 0пт
3×256×256




conv0
64×128×128




conv1
128×64×64



conv2
256×32×32



conv3
512×31×31



logits
1×30×30

Блок *ConvNeXtV2*

